

RAPPORT DE PROJET

Comparaison des plans d'échantillonnage Application aux données PISA 2018

Projet réalisé dans le cadre de la formation

Licence en Mathématiques - Parcours Statistiques et Applications

Projet 7 : Plans combinés (strates + grappes)

Travail réalisé par :

- Katr Nada MAATALLAH
- Cherifa AMIR

Enseignant : Yousri SLAOUI

Année universitaire 2025/2026

Table des matières

Introduction générale	1
Chapitre I : État de l’art sur les méthodes d’échantillonnage	3
Introduction	4
1 Notions fondamentales du sondage	4
1.1 Population et échantillon	4
1.2 Paramètres et estimateurs	4
1.3 Variance de la population	5
2 Échantillonnage simple aléatoire	5
3 Échantillonnage stratifié	6
4 Échantillonnage en grappes	7
5 Plans combinés	8
Conclusion	8
Chapitre II : Présentation des données et méthodologie	10
Introduction	11
1 Présentation de la base de données PISA 2018	11
2 Description des variables retenues	12
2.1 Variable d’intérêt : l’indice socio-économique	12
2.2 Variable de stratification : le sexe	12
2.3 Variable de grappe : l’école	12
3 Préparation et nettoyage des données	13
4 Statistiques descriptives de la population étudiée	13
5 Méthodologie d’échantillonnage appliquée	15
Conclusion	16
Chapitre III : Résultats et discussion	17
Introduction	18
1 Paramètres de la simulation	18
2 Résultats obtenus pour chaque plan d’échantillonnage	19
2.1 Échantillonnage simple aléatoire	19
2.2 Échantillonnage stratifié	19

2.3	Plan combiné : stratification et grappes	20
3	Comparaison globale des résultats	20
4	Analyse de l'efficacité relative	21
5	Discussion des résultats	22
	Conclusion	22
	Conclusion générale	23
	Bibliographie	25

Table des figures

1	Illustration du passage de la population à l'échantillon	5
2	Principe de l'échantillonnage simple aléatoire	6
3	Principe de l'échantillonnage stratifié	7
4	Principe de l'échantillonnage en grappes	8
1	Structure hiérarchique des données PISA utilisées dans cette étude	11
2	Aperçu du jeu de données après préparation	13
3	Répartition des élèves selon le sexe	13
4	Distribution de l'indice socio-économique	14
5	Distribution de l'indice socio-économique selon le sexe	14
6	Illustration des trois plans d'échantillonnage étudiés	15
1	Distribution des moyennes estimées selon le plan d'échantillonnage	21

Introduction générale

L'échantillonnage statistique occupe une place centrale dans la théorie des sondages et dans la pratique de l'inférence. Lorsqu'il est impossible, coûteux ou peu pertinent d'observer l'ensemble d'une population, on a recours à un échantillon afin d'estimer certaines caractéristiques globales, telles que la moyenne ou le total. La qualité de ces estimations dépend non seulement de la taille de l'échantillon, mais aussi du plan de sondage utilisé pour sélectionner les unités.

Parmi les principaux plans d'échantillonnage, le plan d'échantillonnage simple aléatoire sans remise constitue une référence classique en raison de sa simplicité et de ses propriétés théoriques. Toutefois, dans de nombreuses situations réelles, les populations présentent une structure organisée ou hiérarchique. Les individus peuvent en effet être répartis en groupes naturels, comme des élèves au sein d'établissements scolaires, des patients dans des hôpitaux ou encore des ménages dans des zones géographiques. Dans ce contexte, des plans plus élaborés, tels que l'échantillonnage stratifié ou les plans intégrant une structure en grappes, peuvent être envisagés.

La stratification consiste à diviser la population en sous-populations homogènes appelées strates, puis à effectuer un tirage dans chacune d'elles. Cette méthode permet souvent d'améliorer la précision des estimateurs lorsque les strates sont bien choisies. À l'inverse, les plans fondés sur des grappes reposent sur la sélection de groupes d'unités plutôt que d'unités isolées. Ils peuvent présenter des avantages pratiques en matière d'organisation ou de collecte, mais ils peuvent également entraîner une perte de précision lorsque les unités appartenant à une même grappe se ressemblent fortement.

Dans ce projet, nous étudions l'estimation de la moyenne de l'indice socio-économique ESCS à partir des données de l'enquête PISA 2018, en nous limitant aux élèves scolarisés en France. La population considérée présente une structure hiérarchique naturelle, les élèves étant répartis dans des établissements scolaires, ce qui rend pertinente l'étude de différents plans d'échantillonnage. Nous comparons trois approches : le plan d'échantillonnage simple aléatoire sans remise, l'échantillonnage stratifié selon le sexe, et un plan combiné associant stratification et tirage en grappes selon les écoles.

L'objectif principal est de comparer la précision de ces différents plans pour l'estimation de la moyenne de la variable ESCS. Plus précisément, il s'agit d'étudier empiriquement la variabilité des estimateurs obtenus selon chaque méthode et d'évaluer l'effet de

la structure des données sur la qualité de l'estimation.

Pour cela, nous utilisons un sous-ensemble réel des données PISA 2018 correspondant à la France, puis nous mettons en œuvre une procédure de simulation Monte-Carlo fondée sur la répétition des tirages selon chacun des plans étudiés. Les résultats obtenus permettent d'estimer empiriquement la variance des estimateurs et de comparer l'efficacité relative des différentes méthodes d'échantillonnage.

Ce rapport est structuré en trois chapitres. Le premier présente les notions fondamentales du sondage ainsi que les principaux plans d'échantillonnage mobilisés dans cette étude. Le deuxième décrit les données utilisées, les variables retenues et la méthodologie adoptée. Enfin, le troisième expose les résultats de la simulation, en propose une interprétation statistique et discute l'influence de la stratification et de la structure en grappes sur la précision des estimateurs.

Chapitre I

État de l'art sur les méthodes d'échantillonnage

Introduction

Le sondage statistique constitue une approche essentielle pour étudier les caractéristiques d'une population lorsque l'observation exhaustive de toutes les unités est impossible ou trop coûteuse. Dans ce contexte, l'objectif est de sélectionner un sous-ensemble d'unités, appelé échantillon, afin d'estimer certains paramètres de la population.

Le choix du plan d'échantillonnage joue un rôle fondamental dans la qualité des estimations obtenues. En effet, la précision des estimateurs dépend non seulement de la taille de l'échantillon mais également de la méthode de sélection des unités. Plusieurs plans de sondage ont été développés afin de s'adapter aux différentes structures possibles des populations.

Dans ce chapitre, nous présentons les notions fondamentales du sondage statistique ainsi que les principaux plans d'échantillonnage nécessaires à cette étude. Nous introduisons d'abord l'échantillonnage simple aléatoire et l'échantillonnage stratifié, qui font partie des plans comparés dans ce travail.

1 Notions fondamentales du sondage

1.1 Population et échantillon

En statistique, la **population** désigne l'ensemble des unités statistiques sur lesquelles porte l'étude. La taille de la population est généralement notée :

$$N$$

Lorsque l'observation de toutes les unités de la population n'est pas possible, on sélectionne un sous-ensemble appelé **échantillon** dont la taille est notée :

$$n$$

L'objectif du sondage est alors d'utiliser les informations contenues dans l'échantillon afin d'estimer certaines caractéristiques de la population.

1.2 Paramètres et estimateurs

Les **paramètres** décrivent les caractéristiques de la population. Par exemple, la moyenne de la population est définie par :

$$\bar{Y} = \frac{1}{N} \sum_{i=1}^N Y_i \tag{1}$$

où Y_i représente la valeur observée pour l'unité i .



FIGURE 1 – Illustration du passage de la population à l'échantillon

Comme les paramètres de la population sont généralement inconnus, on utilise des **estimateurs** calculés à partir de l'échantillon. L'estimateur de la moyenne est donné par :

$$\hat{\bar{Y}} = \frac{1}{n} \sum_{i \in s} Y_i \quad (2)$$

où s désigne l'échantillon sélectionné.

1.3 Variance de la population

La variance d'une population mesure la dispersion des observations autour de la moyenne. Elle est définie par :

$$S^2 = \frac{1}{N-1} \sum_{i=1}^N (Y_i - \bar{Y})^2 \quad (3)$$

Cette quantité joue un rôle important dans l'étude de la précision des estimateurs.

2 Échantillonnage simple aléatoire

Le plan d'échantillonnage simple aléatoire sans remise (PESR) est l'un des plans les plus simples et les plus utilisés en théorie du sondage. Dans ce plan, chaque unité de la population possède la même probabilité d'être sélectionnée dans l'échantillon.

La probabilité de sélection d'une unité est donnée par :

$$P(i \in s) = \frac{n}{N} \quad (4)$$

L'estimateur de la moyenne de la population reste :

$$\hat{Y} = \frac{1}{n} \sum_{i \in s} Y_i \quad (5)$$

La variance de cet estimateur est :

$$Var(\hat{Y}) = \left(1 - \frac{n}{N}\right) \frac{S^2}{n} \quad (6)$$

où le terme $1 - \frac{n}{N}$ correspond au facteur de correction pour population finie.




FIGURE 2 – Principe de l'échantillonnage simple aléatoire

3 Échantillonnage stratifié

L'échantillonnage stratifié consiste à diviser la population en plusieurs sous-populations homogènes appelées **strates**. On effectue ensuite un tirage d'échantillon dans chacune des strates.

La taille totale de la population peut être écrite :

$$N = \sum_{h=1}^H N_h \quad (7)$$

où N_h représente la taille de la strate h .

L'estimateur de la moyenne stratifiée est donné par :

$$\hat{Y} = \sum_{h=1}^H \frac{N_h}{N} \bar{Y}_h \quad (8)$$

où $\bar{Y}_h$ est la moyenne observée dans la strate h .

La variance de cet estimateur s'écrit :

$$Var(\hat{Y}) = \sum_{h=1}^H \left(\frac{N_h}{N} \right)^2 \frac{S_h^2}{n_h} \quad (9)$$




FIGURE 3 – Principe de l'échantillonnage stratifié

4 Échantillonnage en grappes

Dans l'échantillonnage en grappes, la population est divisée en groupes appelés **grappes**. Au lieu de sélectionner directement des unités individuelles, on sélectionne certaines grappes puis on observe les unités qui les composent.

Si chaque grappe contient M unités et que m grappes sont sélectionnées, l'estimateur de la moyenne peut être écrit :

$$\hat{Y} = \frac{1}{m} \sum_{g \in s} \bar{Y}_g \quad (10)$$

où $\bar{Y}_g$ représente la moyenne observée dans la grappe g .

Un concept important dans ce contexte est l'effet de plan, défini par :

$$DEFF = 1 + (m - 1)\rho \quad (11)$$

où ρ est la corrélation intra-grappe.




FIGURE 4 – Principe de l'échantillonnage en grappes

5 Plans combinés

Dans de nombreuses situations pratiques, les populations présentent à la fois une structure stratifiée et une organisation en grappes. Les plans combinés consistent alors à appliquer une stratification de la population puis à sélectionner des grappes à l'intérieur de chaque strate.

La taille totale de la population peut être écrite :

$$N = \sum_{h=1}^H G_h M_h \quad (12)$$

où G_h est le nombre de grappes dans la strate h et M_h la taille d'une grappe.

L'estimateur de la moyenne peut alors s'écrire :

$$\hat{Y} = \sum_{h=1}^H \frac{N_h}{N} \hat{Y}_h \quad (13)$$

Ces plans permettent souvent d'améliorer l'efficacité du sondage tout en réduisant les coûts de collecte des données.

Conclusion

Dans ce chapitre, nous avons présenté les notions fondamentales du sondage statistique ainsi que les principales méthodes utiles à cette étude. Après avoir introduit les concepts de population, d'échantillon et d'estimation, nous avons décrit l'échantillonnage simple aléatoire, l'échantillonnage stratifié, ainsi que l'échantillonnage en grappes, présenté ici comme base théorique pour comprendre le plan combiné.

Ces éléments constituent le cadre théorique de l'étude menée dans ce projet. Le chapitre suivant présente les données utilisées, la méthodologie adoptée et la comparaison empirique des trois plans étudiés : le PESR, le PEAR et le plan combiné.

Chapitre II

Présentation des données et méthodologie

Introduction

Ce chapitre présente le jeu de données utilisé ainsi que la méthodologie adoptée pour comparer différents plans d'échantillonnage. L'étude repose sur un sous-ensemble des données de l'enquête internationale PISA 2018, limité aux élèves scolarisés en France. L'objectif est d'estimer la moyenne d'une variable quantitative, l'indice socio-économique des élèves, puis de comparer la précision de trois méthodes d'échantillonnage : l'échantillonnage simple aléatoire, l'échantillonnage stratifié et un plan combiné associant stratification et grappes.

1 Présentation de la base de données PISA 2018

Le programme PISA (Programme for International Student Assessment) est une enquête internationale coordonnée par l'OCDE visant à évaluer les compétences des élèves de quinze ans dans différents domaines académiques [1]. Les données utilisées dans cette étude proviennent de l'édition 2018 de l'enquête PISA [2]. En complément de ces évaluations, PISA collecte également des informations détaillées sur le contexte scolaire, social et économique des élèves. Dans ce projet, nous utilisons le fichier **Student Questionnaire Data File 2018**. Ce fichier contient de nombreuses variables décrivant les caractéristiques individuelles et familiales des élèves. Afin de simplifier l'analyse, nous avons restreint l'étude aux observations correspondant aux élèves scolarisés en France.




FIGURE 1 – Structure hiérarchique des données PISA utilisées dans cette étude

2 Description des variables retenues

Après filtrage sur la France et suppression des observations présentant des valeurs manquantes pour les variables retenues, la population étudiée est constituée de 6176 élèves répartis dans 251 établissements scolaires.

Pour mener l'analyse, seules les variables nécessaires à l'étude ont été conservées. Les variables retenues sont les suivantes :

- **pays** : indique le pays de l'élève et permet de sélectionner les observations correspondant à la France ;
- **ecole** : identifiant de l'établissement scolaire fréquenté par l'élève ;
- **sexe** : sexe de l'élève ;
- **indice_socioeco** : indice socio-économique de l'élève (ESCS).

2.1 Variable d'intérêt : l'indice socio-économique

La variable principale étudiée dans ce projet est l'indice socio-économique ESCS (*Economic, Social and Cultural Status*). Cet indice synthétique est construit par l'OCDE à partir de plusieurs informations relatives au contexte familial de l'élève, notamment le niveau d'éducation des parents, leur profession et certaines ressources éducatives disponibles au domicile.

2.2 Variable de stratification : le sexe

La variable **sexe** est utilisée comme variable de stratification. Elle distingue les élèves selon deux modalités : *Fille* et *Garçon*. Ce choix est motivé par sa simplicité d'interprétation et par le fait que les deux groupes sont bien représentés dans la population étudiée.

2.3 Variable de grappe : l'école

La variable **ecole** correspond à l'identifiant de l'établissement scolaire fréquenté par l'élève. Elle est utilisée pour définir la structure de grappe dans le plan combiné étudié dans ce travail.

La population étudiée comprend 251 écoles distinctes. Cette organisation permet de considérer chaque école comme une unité de tirage dans la composante en grappes du plan combiné.

3 Préparation et nettoyage des données

Avant l'analyse, plusieurs étapes de préparation ont été nécessaires. Dans un premier temps, seules les variables utiles à l'étude ont été extraites du fichier d'origine. Les variables ont ensuite été renommées afin de faciliter l'interprétation et la lisibilité du code.

Après ce nettoyage, le jeu de données final comprend 6176 observations.

La Figure 2 présente un aperçu du jeu de données final obtenu après les opérations de préparation.

	country	school_id	gender	escs
	<chr>	<dbl>	<chr>	<dbl>
1	France	25000001	Female	0.0701
2	France	25000001	Female	-0.0699
3	France	25000001	Female	-0.135
4	France	25000001	Male	-0.700
5	France	25000001	Male	-0.986
6	France	25000001	Male	0.332

FIGURE 2 – Aperçu du jeu de données après préparation

4 Statistiques descriptives de la population étudiée

L'étude descriptive de la population met en évidence les caractéristiques suivantes :

- nombre total d'élèves : 6176 ;
- nombre d'écoles : 251 ;
- nombre de filles : 3022 ;
- nombre de garçons : 3154.




FIGURE 3 – Répartition des élèves selon le sexe

On observe que les deux groupes sont relativement équilibrés, ce qui rend pertinente l'utilisation du sexe comme variable de stratification.

Une analyse descriptive de la variable d'intérêt permet ensuite d'observer la distribution de l'indice socio-économique dans la population étudiée.




FIGURE 4 – Distribution de l'indice socio-économique

Les statistiques descriptives obtenues indiquent une moyenne de l'indice socio-économique égale à -0.10931. Les valeurs observées présentent une variabilité relativement importante, ce qui rend pertinent l'étude de différents plans d'échantillonnage pour estimer cette moyenne.

La Figure 5 présente la distribution de l'indice socio-économique selon le sexe des élèves.




FIGURE 5 – Distribution de l'indice socio-économique selon le sexe

5 Méthodologie d'échantillonnage appliquée

L'objectif principal de ce travail est de comparer plusieurs plans d'échantillonnage en évaluant leur capacité à estimer la moyenne de l'indice socio-économique.

Trois plans d'échantillonnage sont étudiés :

- l'échantillonnage simple aléatoire sans remise ;
- l'échantillonnage stratifié selon le sexe ;
- le plan combiné associant stratification selon le sexe et tirage en grappes selon les écoles.

Dans le plan combiné, la population est d'abord divisée en deux strates selon le sexe. À l'intérieur de chaque strate, un certain nombre d'écoles est tiré aléatoirement, puis tous les élèves appartenant à cette strate dans les écoles sélectionnées sont retenus dans l'échantillon.

La Figure 6 illustre de manière schématique les trois plans d'échantillonnage considérés.




FIGURE 6 – Illustration des trois plans d'échantillonnage étudiés

Afin de comparer la précision de ces différentes méthodes, une simulation Monte-Carlo est réalisée. Chaque plan d'échantillonnage est répété un grand nombre de fois, et la moyenne estimée de l'indice socio-économique est calculée à chaque répétition. Les

variances empiriques obtenues permettent ensuite de comparer l'efficacité des différents plans.

Conclusion

Ce chapitre a présenté les données utilisées dans l'étude ainsi que les variables retenues pour l'analyse. Après la description du jeu de données PISA 2018 et la préparation du sous-ensemble correspondant aux élèves français, une analyse descriptive de la variable d'intérêt a été réalisée. Les trois plans d'échantillonnage étudiés ont ensuite été introduits. Le chapitre suivant est consacré à la présentation des résultats obtenus et à leur interprétation.

Chapitre III

Résultats et discussion

Introduction

Ce chapitre présente les résultats obtenus à partir de la simulation Monte-Carlo réalisée sur les données issues de l'enquête PISA 2018 pour les élèves scolarisés en France. L'objectif principal est de comparer la précision de plusieurs plans d'échantillonnage pour l'estimation de la moyenne de l'indice socio-économique des élèves.

Les plans étudiés sont l'échantillonnage simple aléatoire, l'échantillonnage stratifié selon le sexe et le plan combiné associant stratification et grappes. Les simulations permettent d'étudier le comportement de chaque estimateur, d'évaluer sa dispersion et de comparer les méthodes en termes de variance empirique et d'efficacité relative.

1 Paramètres de la simulation

La population étudiée comprend 6176 élèves scolarisés en France, répartis dans 251 établissements scolaires. La variable d'intérêt est l'indice socio-économique ESCS, dont la moyenne réelle dans la population est :

$$\mu = -0.109315$$

La comparaison des différents plans d'échantillonnage a été effectuée à l'aide d'une simulation Monte-Carlo fondée sur les paramètres suivants :

- taille de la population : $N = 6176$;
- nombre d'écoles : 251 ;
- taille d'échantillon de référence : $n = 278$ individus, correspondant à la taille observée lors d'un tirage de référence du plan combiné ;
- nombre de répétitions : $B = 500$.

Dans le plan combiné, la taille de l'échantillon n'est pas fixée directement, mais dépend des effectifs des écoles sélectionnées. La valeur $n = 278$ correspond à la taille observée lors d'un tirage de référence et a été utilisée afin d'assurer la comparabilité avec les plans PESR et PEAR. Dans le plan combiné, dix écoles sont tirées aléatoirement dans chaque strate définie par le sexe des élèves. La taille finale de l'échantillon dépend alors des effectifs observés dans les écoles sélectionnées.

2 Résultats obtenus pour chaque plan d'échantillonnage

2.1 Échantillonnage simple aléatoire

Dans le cas de l'échantillonnage simple aléatoire, les élèves sont tirés directement au hasard dans l'ensemble de la population, sans tenir compte ni de la structure des écoles, ni du sexe des individus. Ce plan constitue la méthode de référence, car il repose sur le principe le plus simple.

Les simulations montrent que la moyenne des estimateurs obtenus sous ce plan est égale à :

$$\bar{Y}_{PESR} = -0.109433$$

Cette valeur est très proche de la moyenne réelle de la population, ce qui indique que l'estimateur est correctement centré. La variance empirique associée à ce plan vaut :

$$Var(\bar{Y}_{PESR}) = 0.003312$$

L'écart-type empirique correspondant est :

$$SD(\bar{Y}_{PESR}) = 0.057551$$

Ces résultats montrent que l'échantillonnage simple aléatoire fournit des estimations relativement stables de la moyenne de l'indice socio-économique.

2.2 Échantillonnage stratifié

Dans le plan stratifié, la population est divisée en deux strates selon le sexe des élèves, puis un tirage aléatoire est effectué à l'intérieur de chaque strate. Cette méthode vise à mieux représenter les deux groupes et à exploiter l'information contenue dans la structure de la population.

La moyenne des estimateurs obtenus par simulation est :

$$\bar{Y}_{PEAR} = -0.109669$$

Cette valeur reste très proche de la moyenne réelle de la population, ce qui confirme le bon centrage de l'estimateur. La variance empirique du plan stratifié est égale à :

$$Var(\bar{Y}_{PEAR}) = 0.003177$$

L'écart-type empirique correspondant est :

$$SD(\bar{Y}_{PEAR}) = 0.056369$$

La variance observée est légèrement inférieure à celle obtenue avec le PESR. Cela indique que la stratification selon le sexe améliore légèrement la précision de l'estimation. Ce résultat s'explique par le fait que la stratification permet de garantir la représentation des deux groupes dans chaque échantillon simulé.

2.3 Plan combiné : stratification et grappes

Le plan combiné associe deux mécanismes : la stratification selon le sexe et le tirage en grappes selon les écoles. Concrètement, la population est d'abord divisée en deux strates, puis un certain nombre d'écoles est sélectionné dans chaque strate, et les élèves appartenant à la strate considérée dans les écoles retenues sont inclus dans l'échantillon.

La moyenne des estimateurs obtenus sous ce plan est :

$$\bar{Y}_{Comb} = -0.107861$$

Cette valeur reste proche de la moyenne réelle de la population, ce qui montre que l'estimateur demeure globalement centré. En revanche, la variance empirique observée est beaucoup plus élevée :

$$Var(\bar{Y}_{Comb}) = 0.019147$$

L'écart-type empirique correspondant vaut :

$$SD(\bar{Y}_{Comb}) = 0.138371$$

Cette forte augmentation de la variance traduit une perte importante de précision. Les estimations obtenues sous ce plan sont beaucoup plus dispersées que celles obtenues avec le PESR ou le plan stratifié. Cette situation s'explique par la présence d'un effet de grappe : les élèves appartenant à une même école tendent à partager des caractéristiques proches, notamment sur le plan socio-économique. Ainsi, lorsque quelques écoles seulement sont tirées, l'information contenue dans l'échantillon est moins diversifiée, ce qui augmente la variabilité de l'estimateur.

3 Comparaison globale des résultats

La Figure 1 présente la distribution des moyennes estimées pour les différents plans d'échantillonnage sur les 500 répétitions de la simulation.

Le tableau 1 résume les principaux résultats obtenus.




FIGURE 1 – Distribution des moyennes estimées selon le plan d’échantillonnage

Plan d’échantillonnage	Taille n	Moyenne estimée	Variance empirique	Écart-type
Plan combiné (strates + grappes)	278	-0.107861	0.019147	0.138371
PESR (simple aléatoire)	278	-0.109433	0.003312	0.057551
PEAR (stratifié)	278	-0.109669	0.003177	0.056369

TABLE 1 – Comparaison des performances des différents plans d’échantillonnage

Les trois plans étudiés produisent des moyennes estimées proches de la valeur réelle de la population. En revanche, leur précision diffère sensiblement. Le plan stratifié est celui qui présente la plus faible variance, suivi de très près par l’échantillonnage simple aléatoire. Le plan combiné est quant à lui nettement moins précis.

4 Analyse de l’efficacité relative

L’efficacité relative permet de comparer la performance d’un plan d’échantillonnage par rapport à un plan de référence, ici le PESR.

Pour le plan stratifié, l’efficacité relative vaut :

$$\frac{Var(\bar{Y}_{PESR})}{Var(\bar{Y}_{PEAR})} = \frac{0.003312}{0.003177} = 1.0424$$

Cette valeur, légèrement supérieure à 1, montre que l’échantillonnage stratifié est environ 4,24 % plus efficace que le plan simple aléatoire.

Pour le plan combiné, l’efficacité relative vaut :

$$\frac{Var(\bar{Y}_{PESR})}{Var(\bar{Y}_{Comb})} = \frac{0.003312}{0.019147} = 0.173$$

Cette valeur très inférieure à 1 montre que le plan combiné est beaucoup moins efficace que le PESR dans ce contexte. L'effet de grappe lié aux écoles dégrade fortement la précision de l'estimation.

5 Discussion des résultats

Les résultats obtenus mettent en évidence l'importance de la structure de la population dans le choix d'un plan d'échantillonnage. Dans cette étude, la stratification selon le sexe permet une légère amélioration de la précision. Cela suggère que cette variable contient une information utile pour organiser le tirage et réduire la variabilité des estimations.

En revanche, l'introduction d'un tirage par grappes fondé sur les écoles conduit à une augmentation marquée de la variance. Ce résultat est cohérent avec la théorie des sondages : lorsque les unités appartenant à une même grappe sont similaires, l'information apportée par chaque nouvelle observation est moins importante que dans un échantillon dispersé aléatoirement dans l'ensemble de la population.

Ainsi, même si le plan combiné peut être avantageux d'un point de vue logistique ou organisationnel, il apparaît ici moins performant du point de vue statistique. Dans le cadre de cette étude, le plan stratifié selon le sexe constitue donc le meilleur compromis entre simplicité et précision.

Conclusion

Les simulations réalisées sur les données PISA 2018 montrent que les différents plans d'échantillonnage conduisent à des estimateurs de moyenne globalement bien centrés sur la moyenne réelle de la population. Toutefois, leur précision varie sensiblement.

L'échantillonnage stratifié selon le sexe apparaît comme la méthode la plus efficace dans cette étude, avec une légère amélioration par rapport à l'échantillonnage simple aléatoire. En revanche, le plan combiné associant stratification et grappes présente une variance nettement plus élevée, ce qui traduit une perte importante de précision.

Ces résultats illustrent le fait que le choix d'un plan d'échantillonnage doit tenir compte non seulement des contraintes pratiques de collecte, mais aussi de la structure réelle des données. Lorsque les unités d'une même grappe sont homogènes, le recours à un plan en grappes peut entraîner une augmentation significative de la variance de l'estimateur.

Conclusion générale

L'objectif de ce projet était de comparer plusieurs plans d'échantillonnage pour l'estimation de la moyenne d'une variable quantitative, à savoir l'indice socio-économique des élèves issu de l'enquête PISA 2018. L'étude s'est appuyée sur un sous-ensemble des données correspondant aux élèves scolarisés en France, permettant d'analyser une population réelle caractérisée par une organisation hiérarchique en établissements scolaires.

Dans un premier temps, les principales méthodes d'échantillonnage ont été présentées d'un point de vue théorique. Cette analyse a mis en évidence les différences fondamentales entre l'échantillonnage simple aléatoire, les plans stratifiés et les plans en grappes, ainsi que les conditions dans lesquelles chacun de ces plans peut être pertinent.

Dans un second temps, une analyse descriptive des données a permis de mieux comprendre la structure de la population étudiée. La répartition des élèves selon le sexe et la distribution de l'indice socio-économique ont été examinées. Cette étape a également mis en évidence la présence d'une structure en grappes liée aux écoles, élément déterminant pour l'étude des plans d'échantillonnage.

La dernière partie du travail a consisté à comparer empiriquement les performances de différents plans d'échantillonnage à l'aide d'une simulation Monte-Carlo. Trois méthodes ont été analysées : l'échantillonnage simple aléatoire, l'échantillonnage stratifié selon le sexe et un plan combiné associant stratification et tirage en grappes.

Les résultats obtenus montrent que les trois méthodes conduisent à des estimateurs de moyenne globalement bien centrés sur la valeur réelle de la population. En revanche, des différences importantes apparaissent en termes de précision. L'échantillonnage stratifié se révèle légèrement plus performant que l'échantillonnage simple aléatoire, ce qui confirme l'intérêt d'utiliser une variable de stratification pertinente. À l'inverse, le plan combiné présente une variance nettement plus élevée, traduisant une perte significative de précision.

Cette diminution de performance s'explique par l'effet de grappe lié aux écoles. Les élèves appartenant à un même établissement ayant des caractéristiques proches, l'information apportée par chaque observation supplémentaire est réduite, ce qui entraîne une augmentation de la variabilité des estimations.

Ainsi, ce travail met en évidence l'importance du choix du plan d'échantillonnage en fonction de la structure des données. Un plan efficace sur le plan logistique n'est pas nécessairement optimal du point de vue statistique. Il est donc essentiel d'adapter la

méthode d'échantillonnage aux caractéristiques de la population étudiée.

Enfin, ce projet pourrait être prolongé en explorant d'autres approches, telles que des plans stratifiés avec allocation optimale ou l'introduction de pondérations. L'étude d'autres variables explicatives pourrait également permettre d'enrichir l'analyse et d'affiner les résultats obtenus.

Bibliographie

- [1] OECD. *PISA 2018 Assessment and Analytical Framework*. OECD Publishing, Paris, 2019. doi : 10.1787/b25efab8-en.
- [2] OECD. *PISA 2018 Results (Volume I) : What Students Know and Can Do*. OECD Publishing, Paris, 2019. doi : 10.1787/5f07c754-en.